大连理工大学软件学院毕业论文（设计）开题报告

<table>
<tr><td>姓名</td><td>张健</td><td>学号</td><td>2022241391</td><td>题目类型</td><td colspan="2">☐校内工程 ☐校内研究
☑校外工程 ☐校外研究</td></tr>
<tr><td>班级</td><td>网 2202</td><td>专业</td><td>网络工程</td><td>开题日期</td><td colspan="2">2026 年 2 月 4 日</td></tr>
<tr><td colspan="2">联系电话</td><td colspan="2">15173062523</td><td>E-mail</td><td colspan="2">3076869480@qq.com</td></tr>
<tr><td colspan="2">中文题目</td><td colspan="5">基于机器学习的网络异常流量检查与溯源系统设计和实现</td></tr>
<tr><td colspan="2">英文题目</td><td colspan="5">Design and implementation of a Network Abnormal Traffic Detection Traceability System Based on Machine Learning</td></tr>
<tr><td colspan="2">外文翻译题目</td><td colspan="5">Anomaly detection in encrypted network traffic using self-supervised learning</td></tr>
<tr><td colspan="2">外文翻译期刊名称、出版年月</td><td colspan="3">Scientific Reports, 2025, 15: 26585</td><td>是否近五年期刊论文</td><td>☑是
☐否</td></tr>
<tr><td colspan="2">校内导师姓名</td><td colspan="2">丁锋</td><td>职称</td><td colspan="2">副教授</td></tr>
<tr><td colspan="2">题目来源</td><td colspan="5">☐科研项目 ☐工程模拟 ☑实际应用 ☐自拟课题 ☐其他</td></tr>
<tr><td colspan="7">校外导师信息（校外题目填写，校内题目以下三行不必填写）</td></tr>
<tr><td colspan="2">校外导师姓名</td><td colspan="2"></td><td>职务/职称</td><td colspan="2"></td></tr>
<tr><td colspan="2">所在单位</td><td colspan="5"></td></tr>
<tr><td colspan="2">联系电话</td><td colspan="2"></td><td>Email</td><td colspan="2"></td></tr>
</table>

一、选题的依据（不少于 1000 字）

1.1 选题背景与应用价值（题目来源、理论意义或工程背景、应用价值等）

题目来源：随着信息化和数字经济的快速发展，网络已成为社会运行和经济活动的基础设施。与此同时，网络攻击呈现出规模化、智能化和隐蔽化的趋势：从传统的端口扫描、DDoS，到利用机器学习规避检测的高级持续性威胁（APT）与针对物联网（IoT）设备的专门攻击，均对网络运行稳定性和信息安全构成严重威胁。我的题目《基于机器学习的网络异常流检测与溯源系统设计与实现》行业对“如何在海量流量中高效发现异常并追溯攻击来源”的共同需求。即在海量的网络攻击中实现对攻击的精确检查以及对于攻击源头与路径的溯源。

理论意义：传统异常检测多依赖规则或基于签名的方法，难以对抗未知或变种攻击。将机器学习（包括监督、无监督、自监督与图神经网络等）引入异常检测，可从统计特征、时序模式与结构关系中挖掘更深层次的异常信号，从而拓展网络安全理论在模式识别与不确定性处理方面的研究。

工程意义：现代网络产生的数据量巨大，实时检测要求系统具备高吞吐与低延迟的流处理能力；同时溯源需要对历史流量进行查询与关联分析，要求存储和索引系统具备可扩展性。

主要应用价值：为提升网络防护能力，基于机器学习的检测模块能够及时识别未知或变种攻击，减少误报与漏报，从而提升企业和组织对网络攻击的防御能力。

1.2 国内外研究现状分析（通过文献综述，分析国内外相关研究进展、存在的问题、技术方案选择依据等）

国内外研究背景：传统基于签名或规则的入侵检测系统（IDS）对已知攻击有较好识别效果，但在面对未知变种、加密流量和低痕迹攻击时表现受限，因此近年来学术界与工业界大量将机器学习与深度学习方法引入网络异常检测领域以提升对新型威胁的检出能力与鲁棒性。在异常流量检测方面，国外研究多集中于利用机器学习和深度学习技术对网络流量特征进行建模。例如，相关研究提出基于深度学习和传统机器学习相结合的入侵检测模型，通过随机森林、XGBoost、长短期记忆网络（LSTM）等算法对网络流量进行分类，从而实现对异常行为的识别。此外，一些研究还提出利用自监督学习方法对加密网络流量进行异常检测，在无需大量标注数据的情况下识别潜在攻击行为，提高了检测的自动化程度和泛化能力。

存在问题：一些深度学习模型虽然具有较高的检测精度，但其模型复杂度较高，对计算资源和数据规模要求较大，在实际网络环境中的部署难度较高。此外，在攻击溯源方面，由于网络数据来源复杂且具有一定的不完整性，攻击路径的重建仍然存在一定困难。同时，现有工作中，异常检测与攻击溯源常被分开研究；将二者有效结合、并在保证实时性与可解释性的同时给出准确的溯源结论，仍需更多方法论与工程验证（例如如何构建可扩展的通信图、如何处理 IP 假冒与日志不完整问题）。

技术方案选择依据：基于上述现状与不足，本文拟在以下两方面展开工作：一是通过设计融合流级统计、时序与会话特征的多维特征体系，并结合监督/无监督模型（如 RandomForest/XGBoost 与 Autoencoder/LSTM），提升在加密与混合流量场景下的异常检测性能；二是将检测结果与图结构分析结合，采用图建模与图算法（或轻量级 GNN）实现攻击路径的重建与可视化，以增强溯源能力并兼顾可解释性与部署可行性。本文的方法力求在保证检测准确率的同时，控制模型复杂度，以便于在实验与准生产环境中验证其有效性。

1.3　参考文献（不少于 8 篇参考文献，格式参照论文模板中参考文献要求）

[1] Sattar S, Khan S, Khan M I, et al. Anomaly detection in encrypted network traffic using self-supervised learning[J]. Scientific Reports, 2025, 15: 26585.

[2] Wang S, Wu H, Cheng G. SD-MDN-TM: A traceback and mitigation integrated mechanism against DDoS attacks with IP spoofing[J]. Computer Networks, 2024, 254: 110793. DOI:10.1016/j.comnet.2024.110793.

[3] Fengrui Xiao, Shuangwu Chen, Jian Yang, et al. GRAIN: Graph neural network and reinforcement learning aided causality discovery for multi-step attack scenario reconstruction[J]. Computers & Security, 2025, 148: 104180.

[4] Prasad N, Diro A, Warren M, Fernando M. A survey of cyber threat attribution: Challenges, techniques, and future directions[J]. Computers & Security, 2025, 157: 104606.

[5] Ren W, Song X, Hong Y, et al. APT attack detection based on graph convolutional neural networks[J]. International Journal of Computational Intelligence Systems, 2023, 16: article 184.

[6] Vibhute A D. Network anomaly detection and performance evaluation of deep learning based models (UNSW-NB15 benchmark)[J]. (Proceedings / journal record), 2024.

[7] Chua W. Web traffic anomaly detection using Isolation Forest[J]. Journal of Information Processing or MDPI (Web Info), 2024, 11(4): 83.

[8] Li J, Zhang X, Xiang H, et al. Federated anomaly detection with Isolation Forest for IoT network traffics[C]//Proc. IEEE ICPADS 2023: 2622–2629.

二、研究内容和方法（不少于 1000 字）

2.1　研究内容与目标（研究内容、研究目标、技术指标等）

研究内容：选取公开数据集（CIC-IDS2017、UNSW-NB15）并结合模拟采集的网络流量，完成缺失值处理、流分割与标签对齐；从流/包层提取统计特征、时序特征与基于会话的聚合特征，探索特征选择与降维方法（如互信息、PCA）；异常检测模型设计：构建并比较监督学习（Random Forest、XGBoost）与无监督/自监督方法（Isolation Forest、对比学习）的性能，尝试结合轻量深度模型对加密流量进行检测；基于异常检测结果，设计基于日志关联与攻击图（NetworkX/GNN 辅助）的溯源流程，实现攻击源 IP 定位、路径重建与可视化展示。

研究目标：实现一套可运行的异常检测与溯源原型系统，支持对典型网络攻击（DDoS、扫描、入侵尝试等）进行实时检测与回溯；在公开数据集上实现检测性能优于常见基线（如单一 Random Forest 或 Isolation Forest）的模型；提供可解释的溯源结果（攻击路径或可疑源 IP 列表），并以可视化界面辅助运维定位与响应；完成系统性能评估报告，给出模型精度、误报率、延迟与溯源准确度等量化结果。

技术指标：检测性能：在 CIC-IDS2017 或 UNSW-NB15 测试集上，目标 Accuracy ≥95%、F1-score≥0.92Recall ≥ 0.93；误报/漏报：False Positive Rate ≤ 3%；实时性与吞吐：单条流处理延迟≤ 200 ms，系统吞吐能力≥1000 flows/s（弱负载场景）；溯源效果：对异常流建立的可疑源 IP 定位准确率≥80%，攻击路径重建准确率≥ 75%（基于日志完整性假设）；可解释性：对每一次报警提供顶级 3 个影响特征与溯源证据（如时间序列、跳数、相关日志条目）。

2.2 拟采取的研究方案（需求分析、理论与技术方法、软硬件开发平台参数、技术路线等）

需求分析：能从 pcap/NetFlow 文件或模拟网络中采集流量（支持 CIC-IDS2017、UNSW-NB15 等数据集导入）。将原始流/包转换为每条 flow 的统计&时序特征（包长、间隔、协议、持续时长、会话聚合等）。实现至少一套监督（Random Forest / XGBoost）和一套无监督（Isolation Forest / Autoencoder）模型并可比较性能。基于异常检测结果，提供可疑源 IP 列表、攻击路径重建与简单可视化（节点—边网络图）。检测模块在离线测试（使用公开数据集）中目标 F1-score ≥ 0.85，模块化设计，便于替换检测模型或扩展溯源算法。提供可复现的训练/测试脚本与实验记录。

理论与技术方法：监督学习（分类）与无监督异常检测理论，用于区分正常/异常样本与发现未知攻击。采用图论与神经网络，用于把通信关系建模为图，从结构上重建攻击传播路径并定位可疑源节点。
特征工程主要有以下：1、流级特征，流持续时间，包总数，字节总数等。2、包级时序特征：包间隔分布，每秒包数变化，滑窗统计等。3，会话/主机特征：源/目的端口分布，协议类型，会话深度等。模型方案主要有以下：1、拟采用 Random Forest（基线）、XGBoost（高性能分类器）与 Isolation Forest、Autoencoder（重构误差检测未知攻击），LSTM 或 1D-CNN，用于捕获序列特征。2、图分析与溯源：NetworkX 建模+图算法（最短路径、介数中心性）或基于 GNN 进行传播路径评分和攻击源估计。3、检测性能指标：Precision、Recall、F1-score、AUC、False Positive Rate（FPR、Detection Latency）。溯源性能指标：攻击源定位准确率（Top-1, Top-3）、路径重建精度、误判路径比例。

软硬件平台采用：
操作系统：Windows 11
编程语言：Python 3.12
数据处理：Pandas、NumPy、scipy
特征与流解析：pyshark、dpkt、scapy（用于解析 PCAP/生成 flow）
机器学习：scikit-learn、xgboost
深度学习：PyTorch
图分析：NetworkX
可视化：Matplotlib
版本控制：Git

技术路线：
数据预处理与下载：下载与预处理公开数据集（CIC-IDS2017、UNSW-NB15、

CTU-13），将 PCAP 转换为 Flow（5 元组+时间窗口）并标注（训练集/验证集/测试集划分）。
特征工程：实现特征提取脚本（flow-level、session-level、time-series slicing），进行特征分布分析、缺失值处理、异常值处理，特征选择：用互信息、方差阈值、递归特征消除（RFE）等方法筛选特征集。
训练基线模型（RandomForest、XGBoost），训练无监督模型（IsolationForest、Autoencoder），训练时序模型（LSTM/1D-CNN）用于补充检测能力。
溯源算法实现：将异常检测结果映射回主机/会话层，构建通信图（节点=IP/主机，边=通信/时间序列），采用图算法（中心性、最短路径、传播概率）或 GNN 对潜在攻击源进行评分与排序。
在测试集上输出各项指标，做对比实验（单模型 vs 融合模型；有/无时序特征；有/无图分析）。

2.3 预期成果与创新性（成果形式、代码量、创新性）

成果形式：设计并实现一套完整的网络异常流量检测与攻击溯源原型系统。系统主要包括数据预处理模块、异常流量检测模块、攻击溯源分析模块以及结果可视化模块。数据预处理模块负责对原始网络流量数据进行解析、清洗以及特征提取；异常检测模块通过机器学习算法对网络流量进行分类识别，判断其是否为异常流量；攻击溯源模块根据检测结果构建网络通信关系图，对攻击路径进行分析与重建，从而定位潜在攻击源；结果可视化模块则以图形化方式展示异常流量检测结果和攻击传播路径，帮助用户更加直观地理解网络攻击行为。

代码量预计：6000-8000 行。

创新性：本研究通过融合流级统计特征、时序特征以及会话特征，构建多维度网络流量特征表示，从而提高模型对复杂网络攻击行为的识别能力，提升异常检测的准确性与稳定性。现有研究多数仅关注异常流量检测，而对攻击行为的进一步分析和溯源研究较少。本研究在完成异常流量检测的基础上，将网络通信关系建模为图结构，并利用图分析方法对攻击路径进行重建，实现异常检测与攻击溯源的结合，从而为网络安全分析提供更加完整的信息支持。

2.4 进度计划（按照“周”展开工作计划，不少于 18 周）

第 1-2 周：文献调研
第 3-4 周：数据集准备与预处理
第 5-8 周：检查模型与开发
第 9-11 周：溯源模块开发
第 12-14 周：系统的集成与测试
第 15-16 周：论文撰写
第 17-18 周：修改完善与答辩准备

指导教师意见： 学生张健已完成课题"基于机器学习的网络异常流量检查与溯源系统设计和实现"的文献调研工作，技术方案可行，时间规划得当，符合开题要求。 签字：丁锋　　2026 年 3 月 11 日	
考核成绩	☑通过　　☐不通过

备注：1、考核组织：开题考核成绩由指导教师给出。

2、考核结论：考核成绩分为通过与不通过两种。

（1）对于不通过者需指出主要问题，导师帮助其分析原因，提出相应的改进措施，待修改完成后再次进行开题。

（2）未提交开题报告或二次考核不合格者，将延期答辩。

3、开题考核结果及开题报告由指导教师统一汇总到教务员处。